Factores Recurrentes en Siniestros de Tránsito Fatales en el Perú, 2021–2025

Guillermo Jordán, Alessandra Munayco, Erick Márquez
Curso: Data Mining
Universidad del Pacífico
Docente: Soledad Espezúa Llerena

***Resumen*—Se analizaron 9 106 siniestros de tránsito fatales ocurridos en el Perú entre 2021 y 2025 para identificar perfiles recurrentes y explorar su distribución espacial. Se integraron datos de siniestros, vehículos y personas. Mediante K-means se identificaron cuatro perfiles asociados con la gravedad del evento, la fuga vehicular, la vigencia del seguro y CITV, y la presencia de motocicletas y conductores sin licencia vigente. Como análisis complementario, DBSCAN permitió identificar ocho agrupaciones espaciales y 359 observaciones clasificadas como ruido con un radio exploratorio de 45 km. Los hallazgos son descriptivos y no permiten establecer causalidad ni estimar el riesgo vial.**

***Index Terms*—siniestros de tránsito, clustering, K-means, seguridad vial, minería de datos**

I. Introducción

Los siniestros de tránsito constituyen un problema relevante para la seguridad vial en el Perú. Durante el año 2024 se registraron 86 757 siniestros y 3 002 personas fallecidas a nivel nacional, lo que evidencia la necesidad de estudiar las características de estos eventos [2].

La información de estos eventos se encuentra distribuida en bases de siniestros, vehículos y personas involucradas. Su integración permite analizar conjuntamente características que, por separado, ofrecen una visión limitada de cada evento.

En este contexto, el objetivo del proyecto es identificar y describir perfiles recurrentes entre los siniestros de tránsito ocurridos en el Perú durante el periodo 2021–2025 que registraron al menos una persona fallecida. Para ello, se utilizan datos abiertos del Observatorio Nacional de Seguridad Vial (ONSV) y técnicas de minería de datos orientadas a encontrar grupos de siniestros con características similares.

Los resultados pueden ser de utilidad para instituciones vinculadas con la prevención y gestión de la seguridad vial, como la División de Prevención e Investigación de Accidentes de Tránsito (DIVPIAT) de la Policía Nacional del Perú, el Ministerio de Transportes y Comunicaciones (MTC) y los gobiernos locales, al facilitar el reconocimiento de perfiles recurrentes de siniestros fatales.

A partir de este objetivo, se plantea la siguiente pregunta de análisis: *¿Qué perfiles recurrentes pueden identificarse entre los siniestros de tránsito fatales ocurridos en el Perú durante el periodo 2021–2025 a partir de las características registradas en las fuentes analizadas?*

II. Datos y representación final

II-A. Fuentes de datos y unidad de análisis

Se utilizaron tres bases de datos abiertas del Observatorio Nacional de Seguridad Vial (ONSV), correspondientes al periodo 2021–2025: siniestros de tránsito fatales, vehículos involucrados y personas involucradas. Estas fuentes contienen información preliminar sobre las características de los eventos, las condiciones de los vehículos y las personas participantes [1].

La unidad de análisis definida es el siniestro de tránsito fatal, de manera que cada observación representa un evento con al menos una persona fallecida. Las tres fuentes se relacionaron mediante el identificador `codigo_siniestro`. Debido a que un siniestro puede involucrar múltiples vehículos y personas, estas dos últimas bases se agregaron por evento antes de integrarlas con la tabla principal.

II-B. Construcción y representación de la matriz analítica

Durante el Hito 2 se revisó la calidad de los datos, se trataron valores faltantes y se integraron las tres fuentes. Asimismo, se construyeron variables derivadas que resumen características de los vehículos y personas involucradas, como la vigencia del seguro y CITV, la fuga vehicular, la presencia de motocicletas, la participación de peatones y la situación de las licencias.

Posteriormente, se realizaron transformaciones sobre variables temporales y categóricas. La hora del siniestro se agrupó en cuatro intervalos y la fecha se representó mediante trimestres. Las variables de zona, causa principal y clase de siniestro se codificaron mediante variables indicadoras, mientras que la red vial se representó con códigos numéricos.

Como resultado, se obtuvo una matriz analítica de 9 106 observaciones y 31 atributos, almacenada en el archivo `matriz_analit.xlsx`. La Tabla I presenta una selección de sus principales variables.

II-C. Transformaciones y exclusiones

Para obtener una representación adecuada, se excluyeron atributos considerados redundantes o poco relevantes para los análisis posteriores, como algunos campos descriptivos de ubicación, características de la vía y causa específica. Se conservaron las coordenadas geográficas para posibilitar el análisis espacial.

Cuadro I
PRINCIPALES VARIABLES DE LA MATRIZ ANALÍTICA

Grupo	Variables representativas
Siniestro	Fallecidos, lesionados, hora, trimestre y red vial.
Vehículos	Número de vehículos, seguro vigente, CITV vigente, vehículos fugados y presencia de motocicletas.
Personas	Número de personas, edad promedio, sexo, peatones, licencia y dosaje etílico.
Contexto	Coordenadas geográficas y variables codificadas de zona, causa y clase de siniestro.

Asimismo, se aplicaron transformaciones a las variables categóricas y binarias para obtener una representación numérica adecuada. Como parte de la preparación de los datos, se realizó la estandarización de las principales variables cuantitativas mediante Z-score, utilizando `StandardScaler`. De esta manera, se obtuvo una versión estandarizada de la matriz analítica para su posterior análisis mediante técnicas de minería de datos.

III. METODOLOGÍA

III-A. Técnica seleccionada

Para identificar perfiles recurrentes entre los siniestros de tránsito fatales se seleccionó K-means, un algoritmo de aprendizaje no supervisado que permite agrupar observaciones según la similitud de sus características.

El algoritmo divide las observaciones en un número predefinido de clústeres, representados por centroides. Durante su ejecución, cada observación se asigna al centroide más cercano y los centroides se actualizan iterativamente para minimizar la suma de las distancias cuadráticas dentro de los grupos [3].

De manera complementaria, se incorporó DBSCAN (Density-Based Spatial Clustering of Applications with Noise), un algoritmo de agrupamiento basado en densidad que permite identificar concentraciones espaciales de observaciones y distinguir puntos aislados como ruido. A diferencia de K-means, DBSCAN no requiere establecer previamente el número de grupos y utiliza parámetros de proximidad y densidad para identificar los agrupamientos [4].

III-B. Justificación de la técnica

La elección de K-means responde a la necesidad de identificar perfiles de siniestros fatales sin disponer de categorías previamente definidas. La matriz analítica construida permite comparar simultáneamente atributos relacionados con la gravedad del evento, los vehículos involucrados y las características de las personas participantes.

El agrupamiento permite reconocer conjuntos de siniestros que presentan características similares y posteriormente describir sus diferencias mediante estadísticas y variables adicionales. Asimismo, los perfiles obtenidos pueden representarse geográficamente para explorar su distribución territorial, sin utilizar la ubicación como criterio de agrupamiento.

DBSCAN complementa este análisis al permitir identificar concentraciones espaciales a partir de las coordenadas geográficas. Así, mientras K-means caracteriza los siniestros según sus atributos, DBSCAN explora su proximidad territorial.

III-C. Supuestos y limitaciones

K-means agrupa las observaciones según su distancia a los centroides y tiende a funcionar mejor cuando los grupos presentan estructuras relativamente compactas. Su desempeño depende de la escala de los atributos, la presencia de valores atípicos, la inicialización de los centroides y el número de clústeres seleccionado. Además, el algoritmo asigna todas las observaciones a un grupo, incluso aquellas que presentan características poco similares a las demás.

En este proyecto, la combinación de variables numéricas y binarias puede influir en las distancias utilizadas para formar los grupos. Por ello, la preparación de los atributos y la evaluación de diferentes configuraciones resultan importantes para obtener perfiles interpretables.

Además, dado que la base analizada contiene únicamente siniestros con al menos una persona fallecida, los grupos identificados describen diferencias dentro de los siniestros fatales, pero no permiten determinar qué factores incrementan la probabilidad de que un siniestro tenga consecuencias fatales frente a otros siniestros.

Por su parte, DBSCAN es sensible a los parámetros de distancia y densidad utilizados para identificar agrupamientos. Asimismo, la distribución de los puntos puede verse afectada por la concentración de registros en determinadas zonas del país y por la disponibilidad o precisión de las coordenadas geográficas. Por ello, sus resultados deben interpretarse como concentraciones espaciales de los eventos registrados y no como una medición directa del riesgo vial.

IV. DISEÑO EXPERIMENTAL

IV-A. Preparación para el agrupamiento

Se utilizó la matriz analítica de 9 106 siniestros fatales, seleccionando diez atributos relacionados con la gravedad del evento y las características de los vehículos y personas involucradas. Se consideraron siete variables numéricas y tres binarias.

Para reducir la influencia de valores elevados, se aplicó la transformación `log1p` a las cantidades de fallecidos y lesionados. Asimismo, se reemplazaron dos registros de edad promedio igual a cero por la mediana de las edades válidas. Posteriormente, las siete variables numéricas se estandarizaron mediante `StandardScaler`, mientras que las binarias conservaron sus valores originales.

Las coordenadas geográficas no participaron en la formación de los clústeres de K-means. Posteriormente, se utilizaron para representar territorialmente los perfiles y como variables de entrada del análisis espacial con DBSCAN.

IV-B. Configuraciones y criterios de evaluación

Se evaluaron valores de K entre 2 y 7 para comparar la calidad de las agrupaciones y su interpretabilidad. En todas las configuraciones se utilizó `k-means++`, diez inicializaciones (`n_init=10`) y una semilla fija (`random_state=42`).

Los experimentos se implementaron en Python utilizando la biblioteca Scikit-learn [5].

Para la comparación se utilizaron tres métricas internas: inercia, coeficiente de Silhouette e índice Davies-Bouldin. La inercia mide la dispersión dentro de los grupos, Silhouette evalúa su cohesión y separación, mientras que Davies-Bouldin compara la dispersión interna con la separación entre clústeres.

Se buscaron valores menores de inercia y Davies-Bouldin, así como valores mayores de Silhouette. Esta última métrica se calculó utilizando una muestra de 1 500 observaciones, mientras que las demás se obtuvieron sobre el conjunto completo.

IV-C. Evaluación y selección de K

La Tabla II presenta los resultados obtenidos para los valores de K evaluados.

Cuadro II
EVALUACIÓN DE K-MEANS SEGÚN EL NÚMERO DE CLÚSTERES

K	Inercia	Silhouette	Davies-B.
2	54063.94	0.229	1.746
3	46236.44	0.245	1.573
4	39938.56	0.247	1.473
5	34306.88	0.271	1.447
6	30510.45	0.285	1.280
7	27733.44	0.289	1.239

La Fig. 1 presenta conjuntamente la evolución de las tres métricas según el número de clústeres; la línea roja discontinua señala la configuración seleccionada, $K = 4$.

La inercia disminuye progresivamente conforme aumenta el número de clústeres. Sin embargo, no se identifica un punto de inflexión suficientemente definido que permita determinar un valor único de K.

El coeficiente de Silhouette presenta una tendencia creciente. Para $K = 4$ se obtuvo un valor de 0.247, lo que refleja una separación limitada entre los grupos.

El índice Davies–Bouldin muestra una reducción general. Para $K = 4$ se obtuvo un valor de 1.473, aunque las configuraciones con mayor número de grupos presentaron mejores resultados en esta métrica.

Considerando los resultados y el propósito exploratorio del estudio, se seleccionó $K = 4$ como configuración final. Aunque valores mayores presentaron mejores métricas internas, se priorizó una segmentación de cuatro perfiles que facilita su caracterización, comparación y representación territorial. Esta decisión responde a criterios de interpretabilidad y no implica que $K = 4$ sea la solución óptima según las métricas evaluadas.

IV-D. Configuración y evaluación de DBSCAN espacial

Como análisis complementario, se aplicó DBSCAN a las coordenadas geográficas de los siniestros, utilizando distancias espaciales para identificar concentraciones de eventos. A diferencia de K-means, este procedimiento no empleó los atributos de gravedad, vehículos o personas para formar los grupos.

Para calcular las distancias geográficas se utilizó la métrica Haversine, convirtiendo previamente las coordenadas a radianes y considerando un radio terrestre medio de 6 371.0088 km. Se evaluaron radios de proximidad de 40, 45, 50, 55 y 60 km, manteniendo `min_samples=50`. Este parámetro establece el número mínimo de observaciones en el entorno de un punto para considerarlo núcleo de un grupo.

Para comparar las configuraciones se consideraron el número de grupos espaciales identificados y la cantidad de observaciones clasificadas como ruido. La Tabla III presenta los resultados obtenidos.

Cuadro III
EVALUACIÓN DE PARÁMETROS DE DBSCAN ESPACIAL

ε (km)	Grupos	Ruido
40	17	529
45	8	359
50	7	246
55	5	186
60	4	158

Al incrementar el radio de proximidad, disminuyeron tanto el número de agrupaciones identificadas como la cantidad de observaciones clasificadas como ruido. Para la exploración cartográfica se utilizó provisionalmente $\varepsilon = 45$ km, con ocho grupos espaciales y 359 observaciones consideradas ruido.

Esta configuración se considera preliminar, pues la selección del radio todavía requiere evaluar la estabilidad y utilidad de las agrupaciones obtenidas. Asimismo, los grupos de DBSCAN representan proximidad geográfica y no deben confundirse con los cuatro perfiles identificados mediante K-means.

V. RESULTADOS PRELIMINARES

V-A. Distribución de los clústeres

La aplicación de K-means con $K = 4$ permitió agrupar los 9 106 siniestros fatales en cuatro perfiles. La Tabla IV presenta la cantidad de observaciones asignadas a cada grupo y su proporción respecto del total analizado.

Cuadro IV
DISTRIBUCIÓN DE SINIESTROS POR CLÚSTER

Clúster	Perfil	Siniestros	%
0	Mayor gravedad	1165	12.8
1	Fuga vehicular	885	9.7
2	Seguro y CITV	3510	38.5
3	Motos y licencia	3546	38.9
	Total	**9106**	**100.0**

Los clústeres 2 y 3 concentran conjuntamente alrededor del 77.5 % de los registros analizados. En contraste, el clúster 1 presenta la menor cantidad de siniestros, con 885 observaciones. Esta distribución permite identificar los perfiles más frecuentes dentro de la muestra, sin que su mayor frecuencia implique necesariamente un mayor riesgo vial.

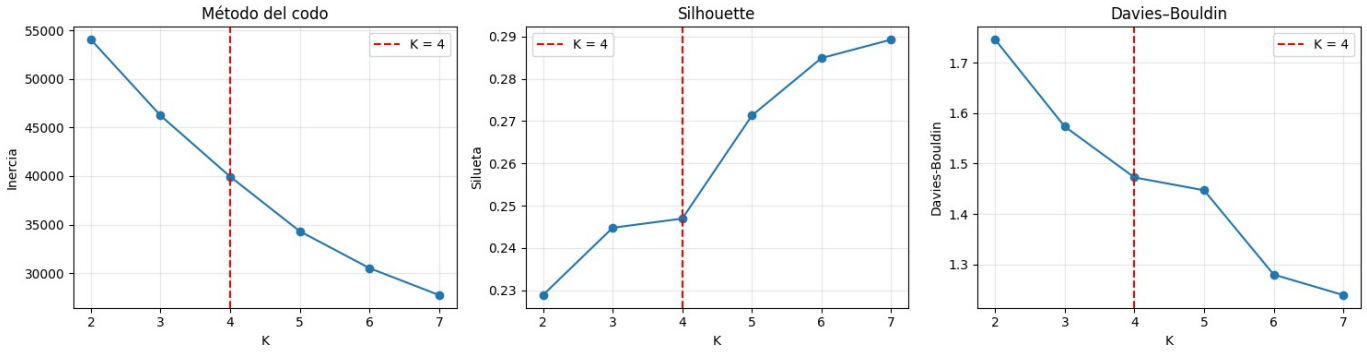


Figura 1. Comparación de la inercia, el coeficiente de Silhouette y el índice Davies–Bouldin para distintos valores de K.

V-B. Caracterización preliminar de los clústeres

Para interpretar los cuatro grupos identificados, se analizaron las características de los siniestros asignados a cada clúster, considerando variables relacionadas con la gravedad de los eventos y las condiciones de los vehículos y personas involucradas.

La Tabla V resume los perfiles obtenidos y sus principales características distintivas.

Cuadro V
CARACTERIZACIÓN PRELIMINAR DE LOS CUATRO CLÚSTERES

Clúster	Perfil	Características principales
0	Mayor gravedad	Mayor cantidad de fallecidos y lesionados por siniestro.
1	Fuga vehicular	Mayor presencia de vehículos que se dieron a la fuga.
2	Seguro y CITV	Indicadores relativamente elevados de seguro y revisión técnica vigentes.
3	Motos y licencia	Mayor presencia de motocicletas y conductores sin licencia vigente.

Los resultados permiten reconocer diferencias entre los siniestros fatales analizados. Mientras algunos grupos destacan por la gravedad de sus consecuencias, otros presentan características asociadas con las condiciones de los vehículos o de los conductores involucrados.

Esta caracterización es descriptiva y no implica que las variables señaladas sean causas directas de los siniestros fatales.

La Fig. 2 presenta los promedios estandarizados de siete variables numéricas utilizadas en el agrupamiento. Los valores positivos indican niveles superiores al promedio general, mientras que los negativos representan niveles inferiores.

El clúster 0 destaca por valores superiores al promedio en fallecidos (1.42) y lesionados (1.80), lo que caracteriza al perfil de mayor gravedad. El clúster 1 presenta una elevada proporción estandarizada de vehículos fugados (2.92), mientras que el clúster 2 registra valores relativamente altos en seguro (0.71) y CITV (0.82). Finalmente, el clúster 3 muestra menores valores de seguro y CITV, y se diferencia adicionalmente por

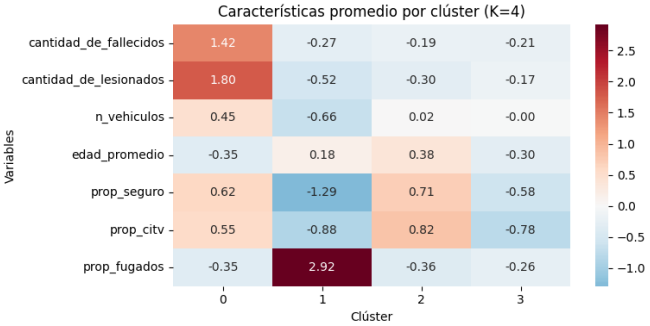


Figura 2. Perfil promedio estandarizado de los cuatro clústeres obtenidos mediante K-means.

la presencia de motocicletas y conductores sin licencia vigente, según la caracterización de las variables binarias.

La caracterización con valores originales permite precisar estas diferencias. El clúster 0 registra un promedio de 2.22 fallecidos y 4.79 lesionados por siniestro. En el clúster 1, la proporción media de vehículos fugados alcanza el 98.8 %, mientras que el 92.2 % de sus eventos corresponde a atropellos. Por su parte, el clúster 2 presenta proporciones medias de seguro y CITV vigentes de 97.1 % y 75.7 %, respectivamente. Finalmente, en el clúster 3, el 59.1 % de los siniestros involucra motocicletas y el 53.9 % registra conductores sin licencia vigente.

V-C. Distribución espacial de los clústeres

Para explorar la distribución territorial de los perfiles obtenidos con K-means, se representaron los siniestros mediante GeoPandas. Las coordenadas se utilizaron únicamente para la visualización posterior al agrupamiento. La Fig. 3 muestra la ubicación de los cuatro perfiles en el Perú y permite observar su distribución geográfica.

La Fig. 4 muestra la participación porcentual de cada clúster entre los siniestros registrados por distrito, complementando el mapa general. Ambas representaciones describen la distribución de los eventos, pero no permiten estimar el riesgo vial, pues no consideran medidas de exposición como el volumen de tránsito.



Figura 3. Distribución espacial de los cuatro perfiles de siniestros fatales en el Perú.

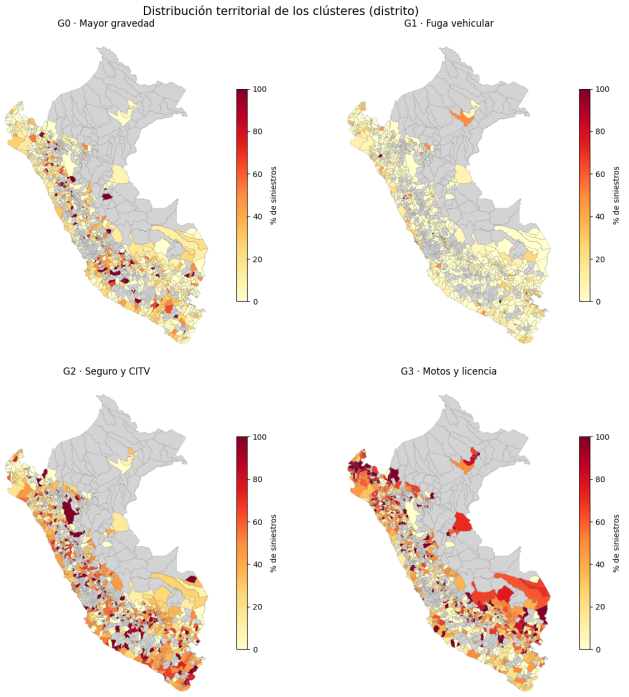


Figura 4. Distribución distrital de los cuatro perfiles de siniestros fatales en el Perú.

V-D. Resultados preliminares de DBSCAN espacial

De manera complementaria, se aplicó DBSCAN para identificar concentraciones espaciales de los siniestros fatales a partir de sus coordenadas geográficas.

Con la configuración exploratoria de $\varepsilon = 45$ km y `min_samples=50`, se identificaron ocho agrupaciones espaciales y 359 observaciones clasificadas como ruido. Estos resultados permiten distinguir zonas con mayor concentración de eventos registrados y puntos que no cumplen las condiciones de densidad establecidas.

A diferencia de los cuatro perfiles obtenidos mediante K-means, los grupos de DBSCAN se forman por proximidad geográfica y no por características de gravedad, vehículos o personas involucradas.

La identificación de estas concentraciones constituye un resultado preliminar, ya que su distribución depende de los parámetros utilizados y de la calidad de las coordenadas disponibles. Por tanto, no debe interpretarse como una medición directa del riesgo vial.

La Fig. 5 muestra las agrupaciones espaciales identificadas mediante DBSCAN y las observaciones clasificadas como ruido.

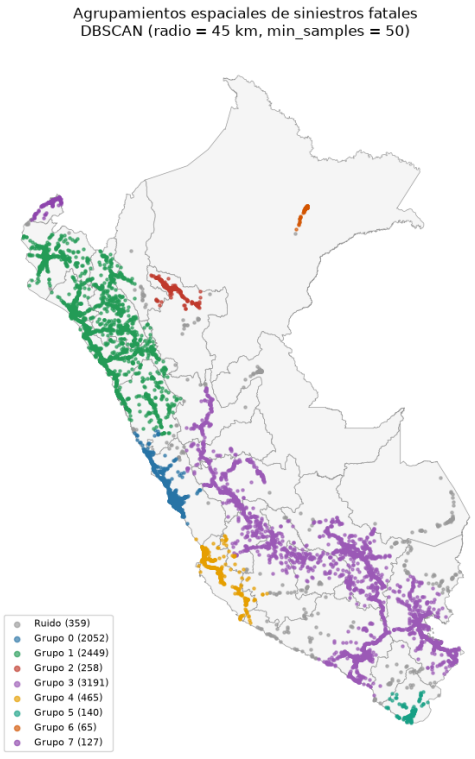


Figura 5. Distribución espacial de los grupos identificados mediante DBSCAN con un radio de 45 km y un mínimo de 50 observaciones.

VI. Problemas, limitaciones y trabajo pendiente

Durante el desarrollo del proyecto se identificaron algunas limitaciones relacionadas con los datos y las técnicas utilizadas. En primer lugar, la base analizada contiene únicamente

siniestros fatales, por lo que los resultados permiten describir perfiles recurrentes, pero no determinar qué características incrementan la probabilidad de un desenlace fatal frente a otros siniestros.

Respecto a K-means, la selección de cuatro clústeres respondió principalmente a criterios de interpretabilidad. El coeficiente Silhouette obtenido ($0{,}247$) indica una separación limitada entre los grupos, mientras que algunas configuraciones con mayor número de clústeres presentaron mejores métricas internas. Por ello, todavía queda pendiente comprobar la estabilidad de los perfiles identificados.

Asimismo, la interpretación de algunos atributos presenta limitaciones. Por ejemplo, en los siniestros con vehículos fugados, la información disponible sobre seguro y revisión técnica puede ser incompleta. Esto dificulta establecer características definitivas de dichos vehículos a partir de los registros analizados.

En el análisis espacial, DBSCAN permitió identificar concentraciones geográficas; sin embargo, la elección de un radio de 45 km es provisional. Los resultados varían según los parámetros de proximidad y densidad, y pueden verse afectados por la precisión de las coordenadas. Además, las concentraciones observadas no representan necesariamente un mayor riesgo vial, debido a que no se consideran medidas de exposición al tránsito.

Antes del Hito 4, se plantea evaluar la estabilidad de K-means con distintas semillas y revisar la sensibilidad de los resultados a la selección y escala de las variables. Para DBSCAN, se buscará profundizar en la comparación de parámetros y examinar la distribución de los grupos espaciales. Finalmente, se completará la discusión de los hallazgos y se elaborarán las conclusiones y recomendaciones correspondientes, considerando el alcance exploratorio del estudio.

REFERENCIAS

[1] Observatorio Nacional de Seguridad Vial, “Datos abiertos de seguridad vial.” [En línea]. Disponible en: https://www.onsv.gob.pe/datosabiertos.

[2] Observatorio Nacional de Seguridad Vial, “Boletín estadístico de siniestralidad vial 2024.” [En línea]. Disponible en: https://www.onsv.gob.pe/post/boletin-estadistico-de-siniestralidad-vial-2024/.

[3] J. MacQueen, “Some methods for classification and analysis of multivariate observations,” in *Proc. 5th Berkeley Symp. Mathematical Statistics and Probability*, vol. 1, 1967, pp. 281–297.

[4] M. Ester, H.-P. Kriegel, J. Sander y X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *Proc. 2nd Int. Conf. Knowledge Discovery and Data Mining (KDD)*, 1996, pp. 226–231.

[5] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.